

数字图像处理技术与应用学习笔记

1 数字图像处理的若干应用方向简介

1.1 数字图像的采集与数字化

数字图像的采集和数字化有两方面的工作：

- (1) 进行图像的采集，数字化的图像以基础图像为蓝本，所以要进行数字图像 的处理，首先 要将需要处理的基础图像进行收集。
- (2) 进行图像的数字化转换。利用计算机技术和数字技术将基础图像信号转化 为数字图像的信号，这样就可以在计算机上进行数字图像的信号处理。


数字图像的处理工作需要要有图像采集和数字转换这两项基本的工作支持，这 样，图像处理的图像信息完整性才可以得到保持。

图像提取技术的发展过程经历了 4 个发展阶段：

- (1) 萌芽阶段：通过拍摄时的布景实现提取条件；
- (2) 初期阶段：以四元像素和数字化为基础， 建立了独立的分支学科；
- (3) 飞跃阶段：以概率统计学原理为基础的提取；
- (4) 分化阶段：认识到视 频中帧与帧之间存在相关性, 产生了专门用于视频提 取的方案。

1.2 图像压缩编码

作为通信、介质存贮、数据发送、多媒体计算机等技术的 关键环节, 图像压缩编码算法的研究是信息技术中最活跃的研究领域之一。图像信息基本都是二维信息，所以信息量十分的巨大。在这样的信息海洋当中进 行处理，无疑会加重处理的难度。为了实现信息处理效率的 提升，积极地将图像信息进行编码处理，使得相关性的内容可以压缩到统一的范围之内。为了使有限的符号表达更多的信息量, 图像压缩既非常必要, 也有可能, 因此产生了各种各样的图像压缩方法。图像压缩编码用尽可能少的数据表示信源发出的图像信号, 以减少容纳给定消息集合的信号空间。通过对图像数据的压缩减少数据占用的存储空间, 从而减少传输图像数据所需的时间和信道带宽。



图一.图像压缩系统模型

1.3 图像增强与恢复

图像增强是按照特定的要求突出一幅图像中的某些信息，同时削弱或去除某些不需要的信息处理方法，其主要目的是使处理后的图像对某种特定的应用来说， 以原来图像更适用,, 它是为了某种应用目的去改善图像质量，使图像更适合于人的视觉特性或机器的识别系统。

图像在获取、传输和存储过程中由于受多种原因如模糊、失真、噪声等的影响，会造成图像质量的下降，即图像的退化。引起图像退化的原因很多，在图像的获取（数字化过程）和传输过程，光照程度和传感器温度是造成图像退化的主要因素。图像在传输过程中主要由于所用的传输信道的干扰受到噪声污染，也会造成图像质量的下降。图像恢复技术以获取视觉质量得到某种程度改善为目的，根据指定的图像退化模型来对在某种情况下退化或降质的退化图像进行恢复，以获取到原始的、未经退化的原始图像。图像恢复首先要建立图像退化/复原模型，当不知道图像本身的性质时，可以建立退化源的数学模型，然后施行恢复算法除去或减少退化源的影响。

1.4 图像分割

图像分割是数字图像处理当中的一项重要内容。数字图像的关联性比较强，所以其是以连续集的方式存在。这样的方式使得图像处理难度增加，所以在处理中需要对图像进行分割。现有常用的两种分割方法：

(1) 基于区域的分割方法：将图像分割成若干不重叠的区域，使各区域内部特征的相似性大于区域间特征的相似性，各区域内像素都满足基于灰度、纹理等特征的某种相似性准则。

(2) 基于边缘的分割方法：边缘的主要表现为图像局部特征的不连续性，该方法首先检出图像中局部特性的不连续性或突变性，然后将它们连成边界，这些边界把图像分成不同的区域。传统的图像边缘检测方法大多可归结为图像高频分量的增强过程，微分运算自然成为边缘检测与提取的主要手段。

1.5 图像分析

图像分析主要有两方面的内容：第一是图像描绘。在经过图像的分割之后，会得到若干区域和边界，而为了能够有效地进行图像的描述，就需要利用图像的相关关系对其进行组织。就目前的图像描绘而言，主要分为两方面的工作，一方面是进行区域内部的描述，另一方面是进行区域的外形边界描述。这两方面的描述会使得描绘工作的效果显著的提升。第二是进行纹理分析。通过结构法、统计法、频谱法以及模型法等进行纹理分析可以获得较为客观的分析结果。

图像分析从图像中抽取某些有用的度量、数据或信息，目的是得到某种数值结果，它主要是提供关于被分析图像的一种描述，既要利用模式识别技术，又要利用关于图像内容的知识库，即人工智能中关于知识表达方面的内容。图像分析需要用图像分割方法抽取出图像的特征，然后对图像进行符号化的描述，这种描述不仅对图像中是否存在某一特定对象作出回答，还要对图像内容作出详细描述。

2 图像增强技术应用背景

在全球信息化大幅发展的时代，对于这个世界的认识越来越依靠于信息的爆炸性传递。大部分人认识世界的主要途径还是眼睛的可视性，人眼所看到的一切都可以化作图像的形式。图像的获取、生成、压缩、存储、变换过程自然会受到各种状况的影响，例如获取图像时会因为天气原因，不同光照条件，图像亮度也有着细微的变化，同样由于仪器设备的质量，参数的设置，人员的操作都会使图像质量在一定程度上的损伤，影响图像的质量。图像增强算法的出现，无疑是对受损的图像做一个“修补”的工作，以此来满足各样的需求。图像增强的目的是为了适应人眼的视觉特性，且易于让机器来进行识别。图像增强涉及了很多领域，其中包括了遥感卫星成像领域、医学影像领域、影视摄影等各领域。

3 图像增强技术国内外发展

3.1 直方图均衡算法

直方图均衡化算法，简言之就是对图像直方图的每个灰度级来进行统计。实现归一化的处理，再对每一灰度值求累积分布的结果，可求得它的灰度映射表，由灰度映射表，可对原始图像中的对应像素来进行修正，生成一个修正后的图像。

3.2 小波变换图像增强算法

19 世纪 80 年代 Morlet 提出小波变换的概念，数学家 Merey 在十几年后提出小波基构造思想，随着 Mallat 的加入，两个人共同建立了小波变换算法。通过小波逆变换将同态滤波处理的低频分量和经自适应阈值、改进模糊增强的高频分量得到增强处理后的红外图像。

小波理论具有低熵和多分辨率的性质，处理小波系数对降噪有一定作用，噪声主要在高通系数中呈现，对高低通子带均需要增强对比度和去噪处理。标准小波变换图像增强 (WT) 将图像分解为 1 个低通子图像和 3 个具有方向性的高通子图像，高通子图像包括水平细节图像、垂直细节图像和对角细节图像。小波变换最大的特点是能较好地用频率表示某些特征的局部特征，而且小波变换的尺度可以不同。

针对传统方法对图像多聚焦模糊特征进行增强会出现图像不清晰、细节丢失现象，小波变换图像多聚焦模糊特征增强方法，利用背景差分法将目标图像的前景区域提取出来，背景区域亮度会随时间发生变化，进而完成背景区域特征更新。根据全局像素点熵值和预设阈值校正加强模糊特征，突出小波变换图像边界局部纹理细节信息，完成增强变换。

3.3 偏微分方程图像增强算法

假设 $V_{l^0}(p)$ 和 $V_l(p)$ 分别为两幅图像 l^0 和 l 的对比度场，若 $V_{l^0}(p)$ 与 $V_l(p)$ 在任一点上有相同的梯度方向，但前者大小均大于后者，则图像应该 l^0 比 l 具有更改的对比度，可以将 l^0 看做 l 的增强图像。实际上，从图像 l 到图像 l^0 的过程就是标准 PDE 图像增强实现的过程，可以由下式子来描述它们的关系：

$$V_{l^0}(p) = k \cdot V_l(p) (\forall p \in \Omega)$$

式中， $V_{l^0}(p)$ 为增强后图像的对比度场； k 为增强因子，一般 $k > 1$ ，过大会增大噪声，对于上式图像的 l 是已知的，其解为：

$$l^0(p) = k \cdot l(p) + \varphi (\forall p \in \Omega)$$

式中， φ 是一个与坐标无关的常数。可看到两幅图像之间的动态范围存在 k 倍的差距。对于可在计算机屏幕上显示的数字图像，其动态范围为 $0 \sim 255$ 。我们要做到先要对的对比度场进行约束，之后开始按照步骤运算，最后才能得到比较准确的数据。

3.4 分数阶微分方程增强算法

近些年，分数阶微积分在多领域都有了突破性进展。分数阶微分不仅可以提升图像中的高频分量，还可以以一种非线性形式保留图像中低频分量所带有的性能。常用的分数阶微分定义有 G-L、R-L、Caputo 三种定义，其中最常用的是采用非整型分数阶微积分的 G-L 定义。

3.5 Retinex 图像增强算法

Retinex 是 retina（视网膜）和 cortexv（大脑皮层）组成的，Retinex 算法由美国物理学家提出。Retinex 理论的基础是人类视觉系统的色彩恒常性，人类视觉感知系统的色知觉存在“先入为主”的特性，即光源条件发生改变，视网膜接收到的彩色信息也会被人们的大脑驳回。Retinex 理论的依据就是原始图像 $S(x, y)$ 可以分解为照射图像 $L(x, y)$ 和反射图像 $R(x, y)$ ，最重要的就是让 $S(x, y)$ 摆脱的 $L(x, y)$ 影响，以便得到图像的反射属性。

3.6 基于深度学习的图像增强算法

3.6.1 卷积神经网络图像增强算法

神经网络 (neural networks) 最基本的组成结构是神经元 (neuron)，神经元概念源于生物神经网络。卷积神经网络 (Convolutional Neural Network, CNN) 在传统神经网络基础上，引入了卷积 (convolution) 和池化 (pooling)，CNN 的建筑灵感来自于视觉感知。CNN 是深度学习领域最重要的网络之一，CNN 在计算机视觉和自然语言处理等诸领域都有很大成就。卷积神经网络的特性比较突出，除了可以实现权值共享外，可调的参数相对来说不多，对二维图像这类的，它的平移、倾斜、缩放包括其他形变都拥有着极高的不变性。CNN 相比于一般的神经网络，具有很大优势：(1) 局部连接。每个神经元只与少数神经元相连，有效地减少了参数，加快了收敛速度；(2) 重量共享。一组连接可做到同时分享相同的权值，进一步降低了所需的参数；(3) 降采样降维。池化层利用图像部分相关的依据对图像进行降采样，降低运算数据量，留存有效的信息值。卷积神经网络大致包含 4 部分，卷积层、池化层、全连接层以及反卷积层，各自具有不同作用，承担独自的工作。深度越深，网络性能越好；随着深度增加，网络性能逐渐饱和。

3.6.2 基于深度学习图像增强的改进算法

Hu 等基于深度学习方法增强 MMSI 亮温图像，设计卷积神经网络重建风云四号卫星 MMSI 的亮温图像和风云三号卫星微波成像仪亮温图像。在根据 SRCNN 进行实现映射函数 $f^o = F(g)$ 式中， g 为监测的天线温度的图像，可用于复原，使其尽可能接近地面真实高分辨率亮温图像 f 。映射函数 F 的完成可以依据学习思想，构建一种卷积神经网络，为了让观测图像数据重新构建为理想的高分辨率数据，需要对卷积神经网络进行一系列特征变换，此过程即达成卷积核的卷积操作。相比古老的插值方法而言，SRCNN 方法除了提高图像的峰值信噪比之外，在提高图像细节较古老的方法也有很大的提高。

4 多级分解的Retinex低照度图像增强算法及分析

4.1 算法背景

生产生活中产生大量低照度环境下获取的图像，它们具有整体亮度低、分辨率低、噪声大等特点，制约了人眼识别和进一步的图像处理和分析。为了提升图像可视化的效果，有必要设计专门的低照度图像增强算法。传统的低照度增强算法一般有：基于伪雾图的增强算法、对比度增强相关算法、和 Retinex 相关算法。

Retinex 相关算认为图像可以表示为照度分量和反射分量的卷积，其中照度分量反应整体变化缓慢的光照信息，反射分量才是图像的本征属性。早期的 Retinex 相关算法通过去除照度分量对图像的影响，将获取的反射分量作为最终增强的图像。早期的 Retinex 相关算法存在严重的色彩失真现象，所以现有的 Retinex 算法同时考虑照度分量和反射分量对图像的影响，通过使用不同的增强函数对分解得到的照度分量和反射分量进行处理从而有效提高图像质量，典型算法包括：非均匀照度图像色彩恢复算法、低照度图像增强算法等。然而这些算法在处理图像时缺少对图像多尺度信息的考虑，使得算法对边缘细节等高频信息增强不足，限制了图像视觉质量的提升。

4.2 算法介绍

Retinex 理论：物体的颜色是由物体对红、绿、蓝光线的反射能力决定的，而不是由反射光强度的绝对值决定；物体的色彩不收光照非均匀性的影响，具有一致性。所以 Retinex 算法核心是通过去除可见光图像的場景光照信息，获取反射图像的分量，实现对图像增强。

基于图像的生成模型，图像可以看做照度分量和反射分量的卷积：

$$U(x, y) = F(x, y) \otimes L(x, y)$$

$F(x, y)$ 表示图像的反射分量; $L(x, y)$ 表示图像的照度分量; $U(x, y)$ 表示原图像, \otimes 代表卷积操作。物体的反射分量在全部反射和全部吸收之间所以 $F(x, y) \in [0, 1]$, 推断出照度分量满足:

$$L(x, y) = U(x, y) / F(x, y) \geq U(x, y)$$

反射分量和照度分量分别刻画了图像的不同方面, 为了获得更好的图像显示效果, 使用不同的增强函数对反射分量和照度分量进行增强, 融合增强后的照度分量和反射分量获得最终增强后的图像。基于分解的 Retinex 图像增强模型可以表示为:

$$U^e(x, y) = f(F(x, y)) \otimes g(L(x, y))$$

基于分解的 Retinex 算法的核心要素是: (1) 获取照度分量的滤波器; (2) 照度分量和反射分量的增强函数; (3) 多尺度的信息保持。

获取照度分量

早期算法一般使用高斯滤波方法获取图像的照度分量, 但是存在颜色失真和光晕效应, 模糊图像不具有保边特性等问题; 所以该算法使用了 Tomasi 等人在1998年的国际计算机视觉大会上提出的具有边缘保持特性的双边滤波方法, 公式如下:

$$BF[U]_p = \frac{1}{W_p} \sum_{q \in \Omega} G_{\sigma_s}(\|p - q\|) G_{\sigma_r}(U_p - U_q) U_q$$

$$W_p = \sum_{q \in \Omega} G_{\sigma_s}(\|p - q\|) G_{\sigma_r}(U_p - U_q)$$

式中: W_p 为归一化因子, 使图像的像素值在滤波前后处在统一范围; p 和 q 表示图像中像素的位置, p 为当前的滤波位置, q 表示 p 的领域 Ω 中的像素位置; U_p 和 U_q 分别表示像素 p 和 q 处的像素值; G_{σ_s} , G_{σ_r} 表示二维高斯滤波核:

$$G_{\sigma}(x) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2}{\sigma^2}\right)$$

双边滤波核包含了图像领域像素值的差异, 所以它能够根据图像领域像素值的差异的改进而自适应的调整, 实现边缘保持。使用不同参数的双边滤波可以实现对图像不同程度的模糊, 在模糊的同时还能够有效保持图像的边缘, 随着参数增加, 双边滤波对图像的模糊呈现逐级递增的效应。


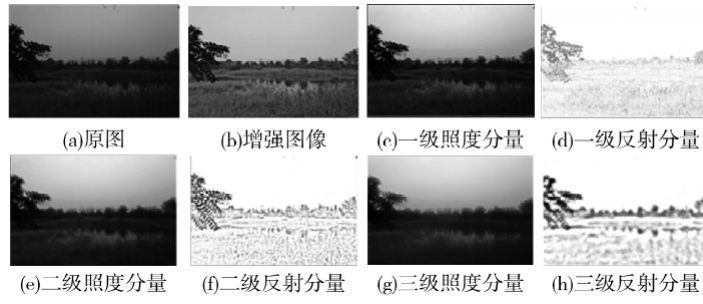


图2. 双边滤波不同参数对图像模糊的影响

参数较小进行滤波图像的细节保留比较多, 可以获取小尺度的反射分量, 此算法逐级增加滤波参数, 获取不同尺度的模糊图像作为照度分量; 同时使用公式: $U(x, y) = F(x, y) \otimes L(x, y)$ 逐级获取不同尺度情况的反射分量。



图三. 图像多级分解示意图

多级分解图像获得图像的多个尺度信息后，对各尺度图像信息进行增强后，通过连乘的方式从获取的各尺度反射分量和最终照度分量来重建图像，以此可以控制各个尺度的增强效果适应更多图像的应用。这个过程可以用下面两个公式来表示：

式1：多级分解图像

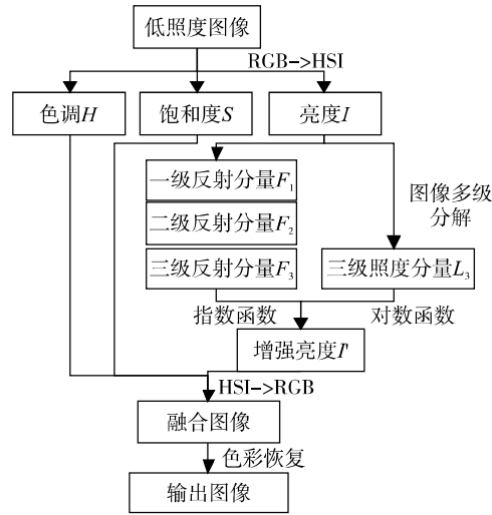
$$U = F_1 \otimes L_1 = F_1 \otimes F_2 \otimes L_2 = F_1 \otimes F_2 \otimes \cdots \otimes F_n \otimes L_n$$

式2：图像增强处理

$$U^e = f(F_1) \otimes f(F_2) \otimes \cdots \otimes f(F_n) \otimes g(L_n)$$

低照度图像增强算法

算法首先将图像从 RGB 颜色空间转换到 HSI 色彩空间，提取亮度通道进行处理；对亮度通道进行多级分解，获取表征图像不同尺度的反射分量和照度分量，为了提升图像不同尺度细节信息的表达能力，使用指数函数对获取的各级反射分量进行处理：提升图像整体亮度，抑制高亮区域；使用 S 型函数对获取的最终照度分量进行处理；如何增强后各分量得到的亮度通道转换回到 RGB 颜色空间，对它进行色彩恢复并输出。流程图如下：



图四. 低照度图像图像增强算法的流程图

为了提升各级反射分量的细节表达能力，采用指数函数对各级反射分量进行处理，公式如下：

$$f(F_k, x_k) = (F_k)^{x_k}$$

其中：下标 k 表示反射分量的序号且 $k \in \{1, 2, 3\}$ ； x_k 表示指数增强系数。由于具体图像增强场景对各尺度细节增强强度的要求不一样，所以对于各级反射分量应设置不同的指数系数。

对照度分量的增强，应在提升图像整体亮度的同时对高亮度区域进行抑制，该算法采用 S 型曲线函数对图像的三级照分量进行处理，即：

$$g(L_3) = \frac{1}{1 + \alpha \sqrt{(1 - L_3)/(L_3 + \varepsilon)}}$$

在对各分量进行增强之后得到增强的亮度通道图：

$$U^e = f(F1, F2, F3) \otimes g(L_n)$$

颜色恢复（多尺度信息保持）

因为增强方法只对图像的亮度图进行处理，而缺少对色调信息的处理，容易造成图像的色彩偏差，为此参考带色彩恢复的多尺度视网膜增强算法(MSRCR)对图像进行颜色恢复。为表达方便，用 $G_i (i = 1, 2, 3)$ 表示原始输入的低照度图像的 RGB 颜色通道； $g_i (i = 1, 2, 3)$ 表示待色彩恢复的图像； $\tilde{g}_i (i = 1, 2, 3)$ 表示色调恢复后的输出图像。颜色恢复的公式可以表示为：

$$C_i = \beta \times \ln \left[1 + \frac{\gamma G_i}{\sum_{j=1}^3 G_j + \theta + 1} \right]$$

$$\tilde{g}_i = C_i \otimes g_i$$

其中： β 表示增益参数； γ 用来调节彩色图像的亮度程度； θ 用来调整三个颜色通道之间的比重； C_i 为各颜色通道的颜色调整因子，通过与待色彩恢复的图像进行卷积操作得到最终的输出图像。

4.2 算法分析

客观评价算法结果，选取局部标准差平均值(average local standard deviation, ALS D)、信息熵(entropy)、平均梯度(average gradient, AG)作为评价指标。

ALS D计算公式：

$$ALS D = \frac{1}{M} \sum_{i=1}^M \left(\sqrt{\frac{1}{25 \times 25} \sum_j^{25 \times 25} (I_j^i - \bar{I}^i)} \right)$$

$$\bar{I}^i = \frac{1}{25 \times 25} \sum_j^{25 \times 25} I_j^i$$

其中： M 表示将原图像分成的块数； I_j^i 表示第 i 个分块上第 j 个位置上的像素值； \bar{I}^i 表示第 i 个分块的平均像素值。

信息熵用于度量图像信息的丰富程度，信息熵越大表明信息越丰富，其定义为：


$$entropy = - \sum_{i=1}^M p(x_i) \lg p(x_i)$$

其中： $p(x_i)$ 表示像素值为 x_i 的概率； M 表示图像像素的总个数。

平均梯度反映图像细节对比的表达能力，它是图像清晰度的重要表征。其计算公式为：

$$AG = \frac{1}{aM_i} \sum_{i=x,y} \sum_{j=1}^M \nabla_j^i$$

其中： ∇_j^i 表示沿 i 方向（ x 表示水平方向、 y 表示垂直方向）上的梯度图像在位置 j 处的梯度值。



图五. 算法对比1



图六. 算法对比2

表 1 低照度图像增强算法客观评价指标比较

Tab. 1 Comparison of objective evaluation for low-illumination image processing algorithms

示例	指标	原图像	算法						
			CLAHE	BPDHE	Dong	MSRCR	ENR	NPEA	本文算法
图 7	DE	7.086 9	7.180 6	6.753 6	6.879 6	7.492 1	7.588 5	7.104 3	7.718 5
	ALSD	15.411 6	23.504	19.231 1	28.226 9	25.254	18.814 5	22.654	36.739 8
	AG	5.410 2	10.932 2	7.876 7	11.701 3	12.739 1	6.965 1	7.833 9	12.033 1
图 8	DE	6.865 1	7.510 7	7.292 6	7.273 3	7.531 6	7.644 1	7.165 7	7.587 3
	ALSD	16.843 2	33.884 2	21.860 2	35.589 5	34.488 7	28.303 4	28.749 6	44.791
	AG	5.869 8	13.400 4	7.871 2	15.598 2	13.941 7	10.203 4	10.48	12.719 4

相比于现有的低照度图像，该算法能够更加有效地提升图像的清晰度、对比度和信息丰富程度。

5 参考文献

- [1] 谢云聪. 数字图像处理的发展与应用趋势讨论. 电子世界, 观察与探索, 2019:8-9.
- [2] 陈炳权, 刘宏立, 孟凡斌. 数字图像处理技术的现状及其发展方向. 吉首大学学报(自然科学版), 2009, 30,1:63-70.
- [3] 靳阳阳, 韩现伟, 周书宁, 等. 图像增强算法综述. 计算机系统应用, 2021, 30(6):18-27.
- [4] 王萍, 孙振明. 多级分解的 Retinex 低照度图像增强算法. 计算机应用研究, 2020, 37(4):1204-1209.